PLANO DE AÇÃO

Dados e Reprodutibilidade

Passo 1 — Reconstrução do banco hidrowize.db

DOCUMENTO	VERSÃO	IDIOMA
Plano — Passo 1	1.0	PT-BR

Sumário

1. 1. Objetivo
2. 2. Diagnóstico das Lacunas
3. 3. Estratégia
4. 4. Plano de Ação
5. 5. Cronograma Sugerido
6. 6. Critérios de Aceite do Passo 1
7. 7. Riscos e Mitigação
8. 8. Decisões Pendentes

Plano de ação para tornar o banco consolidado `data/hidrowize.db` integralmente reproduzível a partir de fontes arquivadas, incluindo os produtos de satélite — em especial a vazão SWOT.

---

1. Objetivo

Garantir que qualquer pessoa (banca, orientador ou outro desenvolvedor) consiga **reconstruir integralmente o banco de dados** a partir de fontes controladas, sem depender de arquivos que só existem em uma máquina local, e sem perder a proveniência dos dados de satélite.

Resultados esperados:

- O comando de reconstrução gera as 16 tabelas com as mesmas contagens registradas.
- Os produtos brutos de satélite (vazão e batimetria) ficam preservados e identificáveis por versão/hash.
- Existe um procedimento de reconstrução testado e documentado.

---

2. Diagnóstico das Lacunas

ID	Lacuna	Evidência	Impacto
L1	NetCDF de vazão SWOT ausente	Não existe `data/satelite/vazao/sa_*.nc`; `gerar_sqlite.py:398-401` retorna 0 quando a pasta não existe	`series_vazao_satelite` (475.111 linhas) não é regenerável sem novo download
L2	Nenhum dado versionado	`.gitignore` ignora `data/` (GeoPackage, NetCDF, banco de 820 MB)	Em clone limpo, o passo 1 exige rodar todos os coletores novamente
L3	Proveniência não registrada	Não há hash/versão dos produtos SICFLOW e SOS Discharge, nem data de coleta	Impossível garantir que uma reconstrução seja idêntica à atual
L4	Sem validação automatizada	Não existe script que confirme as contagens do banco após reconstrução	Erros de reconstrução passam despercebidos

Observação: a pasta `data/satelite/batimetria/` ainda contém o NetCDF SICFLOW (490 MB), mas isso é circunstancial; o fluxo normal do coletor remove os brutos após importar (`_limpar_subpasta`).

---

3. Estratégia

Princípios adotados:

1. **O banco é a fonte de verdade**; os brutos são insumos de reconstrução.

2. **Dados pesados não entram no Git** — permanecem em armazenamento externo.
3. **Todo bruto tem hash e versão** registrados em um manifesto versionado.
4. **Reconstrução é validada por script**, não por inspeção manual.

```
graph LR
    A[Brutos satelite + GeoPackages] -->|hash + versao| M[Manifesto versionado]
    A -->|arquivo| S[Armazenamento externo]
    S -->|rebuild| C[Coletores]
    C --> G[gerar_sqlite.py]
    M -->|confere contagens| V[validar_banco.py]
    G --> D[(hidrowize.db)]
    D --> V
```

---

4. Plano de Ação

Fase A — Preservação das Fontes Brutas

ID	Tarefa	Tipo	Esforço	Depende de
T1	Rebaixar os produtos de satélite (vazão, batimetria, estações) com `coletar_hydroweb.py --tudo --forcar`	Execução	1 h + download	API key HYDROWEB
T2	Adicionar opção `--manter-brutos` ao coletor para não apagar os NetCDF (`backend/coletar_hydroweb.py`)	Código	1–2 h	T1
T3	Arquivar os brutos (NetCDF e GeoPackages) em armazenamento externo organizado por data/versão	Infra	1 h + upload	T1, T2

Detalhes:

- **T1**: o download da vazão SWOT é grande (~1,76 GB) e a batimetria SICFLOW tem ~490 MB. Validar espaço em disco antes. Confirmar `HYDROWEB_API_KEY` no `.env`.
- **T2**: hoje `comando_vazao` e `comando_batimetria` chamam `_limpar_subpasta` ao final, removendo o NetCDF. A nova opção deve pular essa limpeza, preservando o arquivo para reconstrução.
- **T3**: destino sugerido — Drive institucional ou storage de objetos, pasta `satelite/<AAAA-MM>/`, contendo os `.nc`, os `.gpkg` de hidrovias e os zips originais.

Fase B — Proveniência e Validação

ID	Tarefa	Tipo	Esforço	Depende de
T4	Criar manifesto de fontes com hash SHA-256, versão, bbox, data de coleta e contagens	Documentação	2 h	T1

ID	Tarefa	Tipo	Esforço	Depende de
T5	Criar `backend/validar_banco.py` (tabelas esperadas, contagens mínimas, integridade)	Código	3–4 h	—

Detalhes:

- **T4**: gerar `Get-FileHash` (SHA-256) para cada bruto e registrar em `planilhas/satelite_manifest.csv` (versionado) ou `docs/specs/fontes-satelite.md`. Campos: produto, collection ID, versão/data, tamanho, SHA-256, origem (URL STAC), contagem no banco.
- **T5**: o validador deve verificar no mínimo: presença das 16 tabelas, `trechos_navegaveis = 121.661`, `batimetria_sicflow = 1.315.079`, `series_nivel_satelite = 590.698`, `series_vazao_satelite = 475.111`, `cota_fundo_trecho = 121.661`, `estacoes = 75`, e ausência de valores obrigatórios nulos nas chaves.

Fase C — Reconstrução e Verificação

ID	Tarefa	Tipo	Esforço	Depende de
T6	Escrever runbook de reconstrução (ordem e comandos exatos)	Documentação	2 h	T2, T5
T7	Testar a reconstrução em diretório limpo e comparar com o manifesto	Verificação	3–4 h + downloads	T3, T4, T6
T8	Atualizar `estado-atual-projeto.md` e os comentários do `.gitignore`	Documentação	0,5 h	T7

Detalhes:

- **T6**: sequência esperada — coletores ANA (telemetria, cotas, decretos) → `coletar_hydroweb.py` (satélite) → `gerar_sqlite.py` → `validar_banco.py`. Registrar também de onde vêm os GeoPackages de hidrovias.
- **T7**: apagar/renomear o `hidrowize.db`, rodar o runbook do zero e conferir cada contagem contra o manifesto. Evidência de aceite: saída do `validar_banco.py` marcando OK.
- **T8**: marcar a lacuna L1–L4 como resolvida e registrar a decisão sobre versionamento.

---

5. Cronograma Sugerido

Etapa	Tarefas	Duração estimada	Marco
Fase A	T1–T3	1 dia (+ tempo de download)	Brutos preservados e arquivados

Etapa	Tarefas	Duração estimada	Marco
Fase B	T4–T5	1 dia	Manifesto e validador prontos
Fase C	T6–T8	1 dia (+ download)	Reconstrução verificada em ambiente limpo

O caminho crítico é o download dos produtos de satélite (T1); as demais tarefas podem ser adiantadas em paralelo quando não dependem dele.

---

6. Critérios de Aceite do Passo 1

- CA1: Existe backup externo dos NetCDF de vazão e batimetria, com hash registrado.
- CA2: `gerar_sqlite.py`, executado do zero, reconstrói as 16 tabelas com contagens iguais ou superiores às do manifesto.
- CA3: `series_vazao_satelite` é reconstruída sem depender do banco antigo.
- CA4: `validar_banco.py` retorna sucesso e lista as contagens conferidas.
- CA5: O runbook foi executado em diretório limpo por um segundo ambiente, com resultado igual ao registrado.
- CA6: Nenhum insumo indispensável existe apenas na máquina local de origem.

---

7. Riscos e Mitigação

ID	Risco	Probabilidade	Mitigação
R1	Download lento/instável da vazão SWOT (~1,76 GB a ~1 MB/s)	Alta	Baixar uma única vez e arquivar; permitir retomada
R2	Expiração/limite da API key do hydroweb.next	Média	Validar antes de T1; manter o bruto para não depender de novo acesso
R3	Nova versão do produto SICFLOW/SOS altera contagens	Média	Fixar versão e hash no manifesto; tratar contagem esperada como referência da versão
R4	Espaço em disco insuficiente (~2,7 GB satélite + ~2,25 GB GeoPackages)	Média	Arquivar em storage externo; compactar
R5	Auto-limpeza apagar o bruto novamente	Alta se T2 não for feito	Implementar `--manter-brutos` antes de rebaixar

ID	Risco	Probabilidade	Mitigação
R6	Banco de 820 MB não versionado	Certo	Documentar como artefato regenerável; nunca tratá-lo como fonte primária

---

8. Decisões Pendentes

- Definir o **destino do armazenamento externo** dos brutos (Drive institucional, objeto/S3 ou HD externo).
- Decidir se os CSVs compactos (`series_nivel_satelite.csv` , ~54 MB) serão versionados via Git LFS ou mantidos fora do repositório.
- Fixar e registrar a **versão do SICFLOW** (v1/2026) e do SOS Discharge usados, por hash.